Outlook

Re: [arhiv1973b/alexeimacheret] Add files via upload (#1) (0277445)

Отправитель	Alexei Macheret Artur <notifications@github.com>
Дата	28.01.2026, Ср, 22:29
Получатель	arhiv1973b/alexeimacheret <alexeimacheret@noreply.github.com>
Копия	Alexei Macheret Artur <arhiv240@gmail.com>; Your activity <your_activity@noreply.github.com>

import json
import re

def na_vi_integrity_guard(text):
if not text:
return ""

```
# --- ШАГ 1: Защита Идентичности A©тor ---
# Мы временно "маскируем" правильные формы, чтобы общие фильтры их не тронули
text = text.replace("A©тor", "[[ID_RU_VALID]]")
text = text.replace("A©tor", "[[ID_EN_VALID]]")

# --- ШАГ 2: Исправление разрушительных ANSI-переходов ---
# Исправляем артефакты, где английский "захватил" кодировку
replacements = {
    ",v": "w",              # OCR артефакт (w -> ,v)
    "estaЫishing": "establishing", # Смесь латиницы и 'ы'
    "At0r": "A©tor",        # Попытка системы упростить идентичность
    "rea)": "real",         # Ошибка распознавания 'l'
    "mth": "with",          # Ошибка распознавания 'wi'
}

for bad, good in replacements.items():
    text = text.replace(bad, good)

# --- ШАГ 3: Лечение "Сползания" в ANSI (Смешанные слова) ---
# Если в английском слове затесалась кириллица из-за сбоя шрифта/кодировки
def fix_mixed_context(match):
    word = match.group(0)
    # Если это не наш защищенный ID и в слове каша из языков
    if "[[" not in word:
        lat = len(re.findall(r'[a-zA-Z]', word))
        cyr = len(re.findall(r'[a-яA-Я]', word))
        if lat > cyr and cyr > 0: # Явный перекос в латиницу с "мусором"
            trans = str.maketrans("аеоритсхр", "aeopitcxp")
            return word.translate(trans)
    return word

text = re.sub(r'\b[a-zA-Za-яA-Я0-9,.-]+\b', fix_mixed_context, text)

# --- ШАГ 4: Возврат Идентичности ---
text = text.replace("[[ID_RU_VALID]]", "A©тor")
text = text.replace("[[ID_EN_VALID]]", "A©tor")
```

```
return text.strip()
```

def process_and_lock_utf8(input_file, output_file):
print(f"Загрузка архива...")
# Принудительно открываем как UTF-8, игнорируя системные настройки (ANSI)
with open(input_file, 'r', encoding='utf-8', errors='replace') as f:
data = json.load(f)

```
registry = data.get('file_registry', {})

for filename, content in registry.items():
    # Обрабатываем все текстовые слои
    for field in ['raw_text', 'cleaned_text']:
        if field in content:
            content[field] = na_vi_integrity_guard(content[field])

# КЛЮЧЕВОЙ МОМЕНТ: Запись "Бронированного" файла
print(f"Сохранение в режиме 'Stict UTF-8'...")
with open(output_file, 'w', encoding='utf-8') as f:
    # ensure_ascii=False предотвращает превращение символов в \uXXXX
    # Это сохраняет символы в их натуральном виде для шрифта Consolas
    json.dump(data, f, ensure_ascii=False, indent=2)
```

Запуск

input_path = 'transformed_jus_cogens_case_backup_20260126_165959.json'
output_path = 'FIXED_UTF8_ARCHIVE.json'
process_and_lock_utf8(input_path, output_path)
print(f"Готово. Файл {output_path} готов к работе в Consolas.")

—

Reply to this email directly, view it on GitHub, or unsubscribe.
You are receiving this because you are subscribed to this thread.